



西安交通大学
XI'AN JIAOTONG UNIVERSITY

机器学习1: 介绍

Tieliang Gong 龚铁梁

School of Computer Science & Technology,
Xi'an Jiaotong University



任课教师介绍

龚铁梁 (gong-tl.github.io)

副教授 博士生导师



计算机科学与技术学院
跨媒体知识融合与工程应用研究所
陕西省大数据知识工程重点实验室

联系方式：

手机：18209283709

邮箱：gongtl@xjtu.edu.cn
adidasgtl@gmail.com

通讯地址：

西安交通大学兴庆校区彭康楼219

西安交通大学创新港校区泓理楼6036

» 什么是机器学习

机器学习是从人工智能中产生的的一个重要学科分支，是实现智能化的关键

经典定义：从经验观测中总结规律，并对未见数据进行预测

- 随着该领域的发展，目前主要研究**智能数据分析的理论和方法**，并已成为智能数据分析技术的主要源泉之一
- 数据驱动已成为当前机器学习（以深度学习为代表）的主要范式。

图灵奖（机器学习领域）

- **Leslie Valiant**, Harvard, 2011, 计算学习理论奠基人
- **Judea Pearl**, UCLA, 2012, 因果推断方法先驱
- **Yoshua Bengio, Geoffrey Hinton, Yann LeCun**, 2018, 深度学习先驱

机器学习 (Machine Learning)




到底是什么？

举例

文献筛选

在“循证医学”（evidence-based medicine）中，针对特定的临床问题，先要对相关研究报告进行详尽评估。



文献筛选

在一项关于婴儿和儿童残疾的研究中，美国Tufts医学中心筛选了约 33,000 篇摘要，尽管 Tufts 医学中心的专家效率很高，对每篇摘要只需 30 秒钟，该工作仍花费了250小时。




每项新的研究都要重复这个繁琐的过程

需筛选的文章数在不断显著增长


文献筛选

为了降低昂贵的成本, Tufts医学中心引入了机器学习技术。



人类专家只需阅读**50**篇摘要, 系统的自动筛选精度就达到**93%**人类专家阅读 **1,000** 篇摘要, 则系统的自动筛选敏感度达到 **95%** (人类专家以前需阅读 **33,000** 篇摘要才能获得此效果)


机器学习过程



机器学习与数据挖掘

数据挖掘

数据分析技术




数据管理技术



机器学习


数据库

机器学习能做什么





我们可能每都在
用机器学习

例如：互联网搜索



机器学习技术正在支撑着各种搜索引擎

例如：自动驾驶



美国在20世纪80年代就开始研究基于机器学习的汽车自动驾驶技术



机器学习还能做什么

小数据集上work

» 画作鉴别（艺术）

画作鉴别(painting authentication): 确定作品的真伪



出自 [J. Hughes et al., PNAS 2009]

勃鲁盖尔 (1525–1569)
的作品?

梵高 (1853–1890)
的作品?



出自 [C. Johnson et al., IEEE-SP, 2008]

》》画作鉴别（艺术）

除专用技术手段外，**笔触分析** (brushstroke analysis) 是画作鉴定的重要工具；它旨在从视觉上判断画作中是否具有艺术家的特有“笔迹”。

该工作对专业知识要求极高

- 具有较高的绘画艺术修养
- 掌握画家的特定绘画习惯




Portions of van Gogh paintings

**只有少数专家花费很大精力
才能完成分析工作！**

很难同时掌握不同时期、不同流派多位画家的绘画风格！

》》画作鉴别（艺术）

为了降低分析成本，**机器学习**技术被引入



Kröller Müller美术馆与Cornell等大学的学者对82幅梵高真迹和6幅赝品进行分析，自动鉴别精度达 **95%**

[C. Johnson et al., IEEE-SP, 2008]

Dartmouth学院、巴黎高师的学者对8幅勃鲁盖尔真迹和5幅赝品进行分析，自动鉴别精度达 **100%**

[J. Hughes et al., PNAS 2009][J. Mairal et al., PAMI'12]

（对用户要求低、准确高效、适用范围广）

》》 古文献修复（文化）

古文献是进行历史研究的重要素材，但是其中很多损毁严重

Dead Sea Scrolls (死海古卷)

- 1947年出土
- 超过30,000个羊皮纸片段



Cairo Genizah

- 19世纪末被发现
- 超过300,000个片段
- 散布于全球多家博物馆




**高水平专家的大量精力
被用于古文献修复**

》》古文献修复（文化）

一个重要问题：

原书籍已经变成分散且混杂的多个书页，如何拼接相邻的书页？




人工完成书页拼接十分困难

- 书页数量大，且分布在多处
- 部分损毁较严重，字迹模糊
- 需要大量掌握古文字的专业人才

近年来，古文献的数字化浪潮给自动文学修复提供了机会

» 古文献修复（文化）

以色列特拉维夫大学的学者将**机器学习**用于自动的书页拼接



在Cairo Genizah测试数据上，系统的自动判断精度超过 **93%**
新完成约 1,000 篇Cairo Genizah文章的拼接
(对比：过去整个世纪，数百人类专家只完成了几千篇文章拼接)



机器学习还能做什么

大数据集
表现如何?

》》 例如：美国总统大选

How Obama's data crunchers helped him win

《时代》周刊

TIME

By Michael Scherer

November 8, 2012 — Updated 1645 GMT (0045 HKT) | Filed under: [Web](#)



▶▶ 例如：美国总统大选

通过机器学习模型：

- ◆ 在总统候选人第一次辩论后，分析出哪些选民将倒戈，为每位选民找出一个最能说服他的理由
- ◆ 精准定位不同选民群体，建议购买冷门广告时段，广告资金效率比2008年提高14%
- ◆ 向奥巴马推荐，竞选后期应当在什么地方展开活动——那里有很多争取对象
- ◆ 借助模型帮助奥巴马筹集到创纪录的10亿美元


例如：利用模型分析出，明星乔治克鲁尼（George Clooney）对于年龄在40-49岁的美西地区女性颇具吸引力，而她们恰是最愿意为和克鲁尼/奥巴马共进晚餐而掏钱的人……

乔治克鲁尼为奥巴马举办的竞选筹资晚宴成功募集到1500万美元



◆

》》 例如：美国总统大选



队长：Rayid Ghani

卡内基梅隆大学机器学习系首任系主任Tom Mitchell教授的博士生

这个团队行动保密，定期向奥巴马报送各种预测结果；
被奥巴马公开称为总统竞选的“核武器按钮”
(“They are our nuclear codes”)

机器学习源于人工智能

Artificial Intelligence (AI), 1956 -

1956年夏 美国达特茅斯学院

J. McCarthy, M. Minsky, N. Lochester, C. E. Shannon,
H.A. Simon, A. Newell, A. L. Samuel 等10余人



约翰 麦卡锡
(1927-2011)
“人工智能之父”
1971年图灵奖

达特茅斯会议标志着人工智能这一学科的诞生

John McCarthy (1927 - 2011):


1971年获图灵奖，1985年获IJCAI终身成就奖。人工智能之父。他提出了“人工智能”的概念，设计出函数型程序设计语言Lisp，发展了递归的概念，提出常识推理和情境演算。出生于共产党家庭，从小阅读《10万个为什么》，中学时自修CalTech的数学课程，17岁进入CalTech时免修两年数学，22岁在Princeton获博士学位，37岁担任Stanford大学AI实验室主任。

第一阶段：推理期

1956-1960s: Logic Reasoning

- ◆ 出发点：“数学家真聪明！”
- ◆ 主要成就：自动定理证明系统（例如，西蒙与纽厄尔的“Logic Theorist”系统）

渐渐地，研究者们意识到，仅有逻辑推理能力是不够的 …



赫伯特 西蒙
(1916-2001)
1975年图灵奖



阿伦 纽厄尔
(1927-1992)
1975年图灵奖

» 第二阶段：知识期

1970s -1980s: Knowledge Engineering

- ◆ 出发点：“知识就是力量！”
- ◆ 主要成就：专家系统（例如，费根鲍姆等人的“DENDRAL”系统）



爱德华
费根鲍姆
(1936 -)
1994年图灵奖

渐渐地，研究者们发现，要总结出知识再“教”给系统，实在太难了 …

第三阶段：学习期

1990s -now: Machine Learning

- ◆ 出发点：“让系统自己学！”
- ◆ 主要成就：……

机器学习是作为“突破知识工程瓶颈”
之利器而出现的



恰好在20世纪90年代中后期，人类发现自己淹没在数据的汪洋中，对自动数据分析技术——机器学习的需求日益迫切


机器学习 “无处不在”



自动驾驶




金融（量化）



生物信息



AlphaTensor



AlphaZero



AlphaFold

机器学习 “无处不在”

今天的机器学习早已是一个广袤的领域

- ❑ CMU于2006年成立机器学习系
- ❑ MIT的EECS, “软硬兼顾”, 聚焦前沿机器学习模型以及计算方法
- ❑ ...

第42届国际机器学习大会主题

ICML 2024 Call For Papers

The 41st International Conference on Machine Learning (ICML 2024) will be held in Vienna, Austria, July 21st - 27th, and is planned to be an in person conference with virtual elements. In addition to the main conference sessions, the conference will also include Expo, Tutorials, and Workshops. Please submit proposals to the appropriate chairs.

Topics of interest include (but are not limited to):

- General Machine Learning (active learning, clustering, online learning, ranking, reinforcement learning, supervised, semi- and self-supervised learning, time series analysis, etc.)
- Deep Learning (architectures, generative models, deep reinforcement learning, etc.)
- Learning Theory (bandits, game theory, statistical learning theory, etc.)
- Optimization (convex and non-convex optimization, matrix/tensor methods, stochastic, online, non-smooth, composite, etc.)
- Probabilistic Inference (Bayesian methods, graphical models, Monte Carlo methods, etc.)
- Trustworthy Machine Learning (accountability, causality, fairness, privacy, robustness, etc.)
- Applications (computational biology, crowdsourcing, healthcare, neuroscience, social good, climate science, etc.) - we do welcome strong application papers even if there is no new method or theory

This year we are introducing a separate track for position papers. Please consider submitting to this track if you feel that your work would be a better fit for this track instead of the main conference track. We anticipate similar acceptance rates for this track and the main conference track.

» 大数据时代的关键技术



奥巴马提出“大数据计划”后，美国NSF进一步加强资助UC Berkeley研究如何整合将“数据”转变为“信息”的三大关键技术——机器学习、云计算、众包(crowd sourcing)

National Science Foundation: In addition to funding the Big Data solicitation, and keeping with its focus on basic research, NSF is implementing a comprehensive, long-term strategy that includes new methods to derive knowledge from data; infrastructure to manage, curate, and serve data to communities; and new approaches to education and workforce development. Specifically, NSF is:

整合三大关键技术

- Encouraging research universities to develop interdisciplinary graduate programs to prepare the next generation of researchers.
- Funding a \$2 million Expeditions in Computing project based at the University of California, Berkeley, that will integrate three powerful approaches for turning data into information - machine learning, cloud computing, and crowd sourcing;
- Providing the first round of grants to support "EarthCube" – a system that will allow geoscientists to access, analyze and share information about our planet;
- Issuing a \$2 million award for a research training group to support training for undergraduates to use graphical and visualization techniques for complex data.
- Providing \$1.4 million in support for a focused research group of statisticians and biologists to determine protein structures and biological pathways.
- Convening researchers across disciplines to determine how Big Data can transform teaching and learning.

➤➤ 机器学习是大数据时代的必备技术


收集、传输、存储大数据的目的，
是为了“**利用**”大数据

没有机器学习技术**分析**大
数据，“**利用**”无从谈起

一些基本术语

- 监督学习(Supervised learning)
- 无监督学习(Unsupervised learning)
- 半监督学习(Semi-supervised learning)
- 弱监督学习(Weakly supervised learning)

- 假设(Hypothesis)
- 真相(Ground-truth)
- 学习器(Learner)



- 分类
- 回归
- 排序

- 训练集、验证集、测试集
- 示例(instance), 样例(Example), 样本(Sample)
- 属性(Attribute), 特征(feature)
- 属性空间、样本空间
- 输入空间、输出(标记)空间

- 未见样本
- 未知分布
- 独立同分布(i.i.d.)
- 泛化

假设空间

表 1.1 西瓜数据集

编号	色泽	根蒂	敲声	好瓜
1	青绿	蜷缩	浊响	是
2	乌黑	蜷缩	浊响	是
3	青绿	硬挺	清脆	否
4	乌黑	稍蜷	沉闷	否

$$(\text{色泽}=\text{?}) \wedge (\text{根蒂}=\text{?}) \wedge (\text{敲声}=\text{?}) \leftrightarrow \text{好瓜}$$

学习过程 →


在所有假设(hypothesis)组成的空间中进行搜索的过程

目标: 找到与训练集 “匹配” (fit)的假设

假设空间的大小: $n_1 \times n_2 \times n_3 + 1$

版本空间

版本空间(version space): 与训练集一致的假设集合



在面临新样本时, 会产生不同的输出

例如: (青绿; 蜷缩; 沉闷)


**应该采用哪一个
模型(假设)?**

假设空间 vs. 版本空间

比较维度	假设空间	版本空间
定义范围	所有可能的假设	与训练数据一致的假设子集
依赖关系	由模型选择预先确定	由动态数据动态筛选
存在性	非空	可能为空
作用阶段	模型设计阶段确定	训练后生成
示例	所有线性分类器	能正确分类当前训练集的分类器集合

归纳偏好(Inductive bias)

机器学习算法在学习过程中对某种类型假设的偏好



A更好?
B更好?


一般原则:
奥卡姆剃刀
(Ocam's razor)

任何一个有效的机器学习算法必有其偏好


学习算法的归纳偏好是否与问题本身匹配,
大多数时候直接决定了算法能否取得好的性能!

哪个算法更好

没有免费的午餐



(a) A 优于 B



(b) B 优于 A

黑点：训练样本，白点：测试样本

NFL定理：一个算法 $\mathcal{L}_a$ 若在某些问题上比另一个算法 $\mathcal{L}_b$ 好，必存在另一些问题， $\mathcal{L}_b$ 比 $\mathcal{L}_a$ 好。

» NFL定理

简单起见, 假设样本空间 $\mathcal{X}$ 和假设空间 $\mathcal{H}$ 离散, 令 $P(h|X, \mathcal{L}_a)$ 代表算法 $\mathcal{L}_a$ 基于训练数据 X 产生假设 h 的概率, f 代表要学的目标函数, $\mathcal{L}_a$ 在训练集之外所有样本上的总误差为

$$E_{ote}(\mathcal{L}_a|X, f) = \sum_h \sum_{\mathbf{x} \in \mathcal{X} - X} P(\mathbf{x}) \mathbb{I}(h(\mathbf{x}) \neq f(\mathbf{x})) P(h | X, \mathcal{L}_a)$$

考虑二分类问题, 目标函数可以为任何函数 $\mathcal{X} \mapsto \{0, 1\}$, 函数空间为 $\{0, 1\}^{|\mathcal{X}|}$, 对所有可能的 f 按均匀分布对误差求和, 有

$$\sum_f E_{ote}(\mathcal{L}_a|X, f) = \sum_f \sum_h \sum_{\mathbf{x} \in \mathcal{X} - X} P(\mathbf{x}) \mathbb{I}(h(\mathbf{x}) \neq f(\mathbf{x})) P(h | X, \mathcal{L}_a)$$

» NFL定理

$$\begin{aligned}\sum_f E_{ote}(\mathcal{L}_a | X, f) &= \sum_f \sum_h \sum_{x \in \mathcal{X} - X} P(x) \mathbb{I}(h(x) \neq f(x)) P(h | X, \mathcal{L}_a) \\&= \sum_{x \in \mathcal{X} - X} P(x) \sum_h P(h | X, \mathcal{L}_a) \sum_f \mathbb{I}(h(x) \neq f(x)) \\&= \sum_{x \in \mathcal{X} - X} P(x) \sum_h P(h | X, \mathcal{L}_a) \frac{1}{2} 2^{|\mathcal{X}|} \\&= \frac{1}{2} 2^{|\mathcal{X}|} \sum_{x \in \mathcal{X} - X} P(x) \sum_h P(h | X, \mathcal{L}_a) \\&= 2^{|\mathcal{X}|-1} \sum_{x \in \mathcal{X} - X} P(x) \cdot 1\end{aligned}$$

总误差与学习算法无关!



所有算法一样好!

NFL定理的重要前提：

所有问题“出现”的机会相同，
或者所有问题同等重要

- ❑ 实际情况并非如此；我们通常只关注自己想要解决的问题
- ❑ 脱离具体问题，空泛地谈论“什么学习算法更好” 毫无意义！

具体问题，具体分析



西安交通大学
XI'AN JIAOTONG UNIVERSITY

谢谢!

